

主専攻実験 第13回

機械学習を用いた実験

- 評価実験のお作法
- 機械学習モデルにおける判定理由の提示
- 学習データセットとデータ拡張
- 半教師あり学習



機械学習・深層学習モデルの評価方法

評価の重要性は「再現性」

「このモデルは性能が良い」というためには、
優れた結果がたまたま得られたのではないことを示す必要アリ

たまたま優れた結果になる原因として考えられるもの

- 初期値のばらつき
→ 初期値を変えて何回か学習を試すべき
Local Minimum問題
- 学習/テストサンプルのばらつき

学習/テストサンプルのばらつき → Cross Validation

4-fold validation (k=4)



LOOCVも


評価指標の基本

混同行列 Confusion Matrix

行を真値, 列を推定値,
各セルにテストサンプル数を入れた行列

場合によっては
行か列の方向で正規化することも

どのクラスを何に間違えたのか?
→その原因は? 共通点は?



評価指標 Accuracy, Recall, Precision

		Predicted	
		0	1
Actual	0	TN	FP
	1	FN	TP

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$


$$Accuracy =$$

$$\frac{TN + TP}{TN + FP + FN + TP}$$

評価指標 他クラス分類の場合

- Micro Accuracy
全サンプルに対する Accuracy
- Macro Accuracy
各クラスの Accuracy の平均値

基本的には Micro Accuracy
ただし、サンプルバランスが
悪い場合は Macro Accuracy
の方がベター



評価指標 Accuracyの問題点

Accuracyは、あまり当てにしてはいけない。

→ サンプルバランスが悪い時に高くなりやすい
例) 99%がHi, 1%がLowのサンプルに対して,
判定器がすべてHiを出力したケース → Acc. 99%

サンプルの事前確率を考慮した指標にしましょう

→ (情報科学・工学) F1 score
(医学医療系) κ 係数

評価指標 F1 scoreと κ 係数

		Predicted	
		0	1
Actual	0	TN	FP
	1	FN	TP

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

F1 score

$$2 * \frac{Recall * Precision}{Recall + Precision}$$

Mean F1 score

F1 scoreのMacro平均
→不均衡サンプルに対応

評価指標 F1 scoreと κ 係数

		Predicted	
		0	1
Actual	0	TN	FP
	1	FN	TP

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

K 係数

Actual 0 をたまたま 0 と判定する確率

$$P_0 = \frac{FN + TP}{All} \cdot \frac{FP + TP}{All}$$
$$P = \sum P_k$$

$$K = \frac{Accuracy - P}{1 - P}$$


K 係数 > 0.8 で「完全な一致」とみなされる

ROC曲線とAUROC

2値分類において、
内部電位の高い順に
サンプルを並び替え.

グラフの減点からスタート
サンプルがTrueなら一歩上
Falseなら一歩右に移動し
描いた曲線 = ROC

AUROC = ROCの下側の
エリアの面積



判定根拠の提示

深層学習モデルにおける 判定理由の提示

医療分野で新規診断手法を普及させるためには、

「医師の信頼獲得」が一番重要


医師にとって「深層学習モデル」なんて未知！
信用できない！

→判断根拠が医師と同一であること、
(= Interpretability)
各判断に対して理由を提示できること
(= Explainability)
の2点が重要に！




深層学習モデルの根拠提示

Class Activation Mapping




深層学習モデルの根拠提示

Grad-CAM





深層学習モデルの根拠提示

U-Net



Sleep-CAMの場合



Augmentationと 半教師あり学習

生体信号認識と深層学習の相性

👍 医師・技師による知見が豊富
これを反映させたモデル開発が容易

👍 とはいえ、言語化されていない部分も多い。
→ ルールベースよりも統計ベースの機械学習

👎 データセットの用意が困難というか面倒

×

深層学習の「大量の学習サンプルが必要」という特性


→ 「データセットの拡張」

データ拡張とは？

深層学習等の多くの学習サンプルが必要となる課題において、
実際に計測した学習サンプルから
異なる特徴を持つ別の学習サンプルを生成すること

生成と聞くと「ニューラルネットによる画像生成」を
イメージするが、実際には「もっと単純な生成方法」を取る。

例) 画像をターゲットとしたデータ拡張



生体信号の場合

実はあまり普及した方法がない.






データオーグメンテーションの基本は,
「変形後もラベルが変わらない」ことだが, それが困難.

とはいえ, 一般的には大きく 3 種類

- 時間的オーグメンテーション
- 周波数的オーグメンテーション
- 空間的オーグメンテーション

時間的オーグメンテーション

単チャンネルに着目し，時間軸上で波形をいじる方法




周波数的オーグメンテーション

単チャンネルに着目し，時間軸上で波形をいじる方法

実例作れなかった．．．

- FT Surrogate
各周波数成分の**位相**をランダムにシフト
- Frequency Shift
周波数スペクトル（**周波数全体**）をランダムにシフト
- Band stop Filter
適当な周波数を 0 に




電極の配置 (10-20 法)

空間的オーグメンテーション

複数チャンネル計測している場合の方法

- Channel Symmetry
左右のチャンネルをランダムに交換
- Channel Dropout
ランダムなチャンネルの値を 0 に
- Channel Shuffle
ランダムなチャンネルの値を交換




Crop & Resize

比較的うまくいくことが知られているAugmentation方法

Crop: 30秒の信号を
ランダムな位置でカット

Resize: 引き延ばして30秒に

実装的には,
時間空間上でCropしたものを
オーバーサンプリング



対照学習

Contrastive Learning

半教師あり学習の一つ.

信号が「似ている」「似ていない」を定義できるのであれば,
似た信号から得た特徴量は特徴空間上で近く,
似ていない信号の特徴量は // 離れているはず.

→これを満たすように特徴抽出部を最適化

実計測した信号と

これからオーグメンテーションした信号は「似ている」はず

→対照学習を実行する例も

対照学習 Contrastive Learning


つまり、

original

augumented

original

other original



2つの抽出特徴量のcos類似度が高く

別のoriginal信号はcos類似度が低く


なるようにそれぞれ学習すればよい

対照学習 Contrastive Learning

その後、FC層をカット & 元の判定器をつけて
転移学習アプローチ

- ・ 特徴抽出器を固定して
判定器部分のみ学習
- ・ 全体をFine Tuning

などなど



対照学習

Contrastive Learning

「バッチ単位」でのロスについて考える.

あるバッチには

1. N個のオリジナルのエポック
2. N個の水増しエポック

の計 $2N$ 個のデータが含まれている.

z_i : エポック i の抽出特徴

$z_{\hat{i}}$: エポック i から Augment したデータ抽出特徴
とする.

対照学習

Contrastive Learning

類似度関数は一般的なCos類似度,

$$\text{sim}(z_i, z_j) = \frac{z_i \cdot z_j}{\|z_i\| \|z_j\|}$$

エポック*i*に対する損失関数は,

$$l(z_i, z_{\hat{i}}) = \frac{\exp(\text{sim}(z_i, z_{\hat{i}})/\tau)}{\sum_{j \neq i} \exp(\text{sim}(z_i, z_j)/\tau)}$$

全体の損失関数は

$$L = \frac{1}{2N} \sum_{i \in N} l(z_i, z_{\hat{i}}) + l(z_{\hat{i}}, z_i)$$

オーグメンテーションと 対照学習の問題点

睡眠ステージ判定の場合、
期待ほど判定精度が改善しない場合が多いのであまり期待しない

例) Sign Flip → K複合波の陰性鋭波が陽性鋭波に
FT-Surrogate → 紡錘波が紡錘状でなくなる

Crop & Resizeの場合、周波数情報は保持されないが、
波形形状はそこまで壊れないのでうまくいっている？

人間はタイムスケールが変わってもステージ判定可能
→近いことが起こっている？