

主専攻実験 第13回

機械学習を用いた実験

- 学習データセットとデータ拡張
- 評価実験のお作法
- 機械学習モデルにおける判定理由の提示とU-Net



生体信号認識と深層学習の相性

👍 医師・技師による知見が豊富
これを反映させたモデル開発が容易

👍 とはいえ、言語化されていない部分も多い。
→ルールベースよりも統計ベースの機械学習

👎 データセットの用意が困難というか面倒

×

深層学習の「大量の学習サンプルが必要」という特性


→「データセットの拡張」

データ拡張とは？

深層学習等の多くの学習サンプルが必要となる課題において、
実際に計測した学習サンプルから
異なる特徴を持つ別の学習サンプルを生成すること

生成と聞くと「ニューラルネットによる画像生成」を
イメージするが、実際には「もっと単純な生成方法」を取る。

例) 画像をターゲットとしたデータ拡張



生体信号の場合

実はあまり普及した方法がない.






データオーグメンテーションの基本は,
「変形後もラベルが変わらない」ことだが, それが困難.

とはいえ, 一般的には大きく 3 種類

- 時間的オーグメンテーション
- 周波数的オーグメンテーション
- 空間的オーグメンテーション

時間的オーグメンテーション

単チャンネルに着目し，時間軸上で波形をいじる方法




周波数的オーグメンテーション

単チャンネルに着目し，時間軸上で波形をいじる方法

実例作れなかった．．．


- FT Surrogate
各周波数成分の**位相**をランダムにシフト
- Frequency Shift
周波数スペクトル（**周波数全体**）をランダムにシフト
- Band stop Filter
適当な周波数を 0 に



空間的オーグメンテーション

複数チャンネル計測している場合の方法

- Channel Symmetry
左右のチャンネルをランダムに交換
- Channel Dropout
ランダムなチャンネルの値を 0 に
- Channel Shuffle
ランダムなチャンネルの値を交換



対照学習

Contrastive Learning

半教師あり学習の一つ.

信号が「似ている」「似ていない」を定義できるのであれば、
似た信号から得た特徴量は特徴空間上で近く、
似ていない信号の特徴量は // 離れているはず.

→これを満たすように特徴抽出部を最適化

実計測した信号と

これからオーグメンテーションした信号は「似ている」はず

→対照学習を実行する例も

オーグメンテーションと 対照学習の問題点

睡眠ステージ判定の場合，期待ほど判定精度が改善しない

- オーグメンテーションの内容と
特徴波，見極めるポイントのバリエーションの広さ

例) Sign Flip → K複合波の陰性鋭波が陽性鋭波に
FT-Surrogate → 紡錘波が紡錘状でなくなる

データ不均衡対策

クラス認識課題において、
各クラスのサンプルが極端に不均衡な場合がある。

例) N1ステージの割合が少ない, , 等.

→普通に学習させると数の少ないクラスに適した特徴抽出が不可
& 事前確率の極端な違い →出力されない. .

データ不均衡対策

<サンプル自体を調整>

- オーバーサンプリング, アンダーサンプリング
少ないクラスのサンプルを複数回学習 (オーバー)
多いクラスのサンプルを間引いて学習 (アンダー)

<損失関数の調整>

- 少ないクラスの損失をN倍
→他のクラスよりも正確に判定するモチベーションUP

機械学習・深層学習モデルの評価方法

評価の重要性は「再現性」

「このモデルは性能が良い」というためには、
優れた結果がたまたま得られたのではないことを示す必要アリ

たまたま優れた結果になる原因として考えられるもの

- 初期値のばらつき
→ 初期値を変えて何回か学習を試すべき
Local Minimum問題
- 学習/テストサンプルのばらつき

学習/テストサンプルのばらつき → Cross Validation

4-fold validation (k=4)



LOOCVも


評価指標の基本

混同行列 Confusion Matrix

行を真値，列を推定値，
各セルにテストサンプル数を入れた行列

場合によっては
行か列の方向で正規化することも

どのクラスを何に間違えたのか？
→その原因は？共通点は？



評価指標 Accuracy, Recall, Precision

		Predicted	
		0	1
Actual	0	TN	FP
	1	FN	TP

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$


$$Accuracy =$$

$$\frac{TN + TP}{TN + FP + FN + TP}$$

評価指標 他クラス分類の場合

- Micro Accuracy
全サンプルに対する Accuracy
- Macro Accuracy
各クラスの Accuracy の平均値

基本的には Micro Accuracy
ただし、サンプルバランスが
悪い場合は Macro Accuracy
の方がベター



評価指標 Accuracyの問題点

Accuracyは、あまり当てにしてはいけない。

→ サンプルバランスが悪い時に高くなりやすい
例) 99%がHi, 1%がLowのサンプルに対して,
判定器がすべてHiを出力したケース → Acc. 99%

サンプルの事前確率を考慮した指標にしましょう

→ (情報科学・工学) F1 score
(医学医療系) κ 係数

評価指標 F1 scoreと κ 係数

		Predicted	
		0	1
Actual	0	TN	FP
	1	FN	TP

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

F1 score

$$2 * \frac{Recall * Precision}{Recall + Precision}$$

Mean F1 score

F1 scoreのMacro平均
→不均衡サンプルに対応

評価指標 F1 scoreと κ 係数

		Predicted	
		0	1
Actual	0	TN	FP
	1	FN	TP

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

K 係数

Actual 0 をたまたま 0 と判定する確率

$$P_0 = \frac{FN + TP}{All} \cdot \frac{FP + TP}{All}$$
$$P = \sum P_k$$

$$K = \frac{Accuracy - P}{1 - P}$$


K 係数 > 0.8 で「完全な一致」とみなされる

ROC曲線とAUROC

2値分類において、
内部電位の高い順に
サンプルを並び替え.

グラフの減点からスタート
サンプルがTrueなら一歩上
Falseなら一歩右に移動し
描いた曲線 = ROC

AUROC = ROCの下側の
エリアの面積



深層学習モデルにおける 判定理由の提示

医療分野で新規診断手法を普及させるためには、

「医師の信頼獲得」が一番重要


医師にとって「深層学習モデル」なんて未知！
信用できない！

→判断根拠が医師と同一であること、
各判断に対して理由を提示できること
の2点が重要に！




深層学習モデルの根拠提示

Class Activation Mapping



深層学習モデルの根拠提示

Grad-CAM



深層学習モデルの根拠提示

U-Net

